离散纵向数据的混合 GLMM 聚类

误差控制 MCEM、高斯变分近似与积分参照

课程大作业基础修订版

2026 年 11 月 11 日

摘要

建立随机截距混合广义线性混合模型，用于二元、Poisson 和负二项纵向数据的个体聚类。实现独立重要性抽样 MCEM、高斯变分近似（GVA），以一维积分最大似然作参照。MCEM 最大化一个加权目标，并用独立样本评估更新增量误差；GVA 对 Poisson 使用解析期望。模拟覆盖轨迹分离、样本量、序列长度、簇数误设、方差及不规则时间。基准中 GVA 的平均 ARI 为 0.885，积分参照为 0.885；分离减半时 GVA 降至 0.411。另在同一固定参数下比较变分近似、条件 MCMC 与积分。参数均为点估计，不将潜变量分布当作参数后验，不声称多起点获得全局最优。

1 引言

离散纵向数据兼有非高斯响应和个体内相关。混合 GLMM 将整条个体序列分配给一个潜在簇，以簇特异轨迹描述组间差异，以随机效应描述组内异质性。Zeger–Karim[1] 讨论分层 GLMM 及条件随机效应抽样；McCulloch[2] 研究 MCEM、MCNR 和 SML 等似然算法；Booth–Hobert[3] 利用独立抽样评估 MC 误差并增样。本文结合这些思想构造混合模型 MCEM，并用 Ormerod–Wand[4] 的高斯变分近似作现代扩展。更新验证还参考 Caffo 等 [5] 的上升思想，但下面的抽样、误差公式及预算为明确说明的本题适配，不是对其完整程序的复现。

2 模型与似然

个体 $i = 1, \dots, n$ 独立，时点为 t_{ij}，$j = 1, \dots, T_i$。设

$$U_i \sim \mathrm{Cat}(\pi), \quad b_i \mid U_i = k \sim \mathcal{N}(0, D_k), \quad \eta_{ijk} = \beta_{0k} + \beta_{1k} t_{ij} + b_i.$$

给定 (U_i, b_i) 后时间点条件独立。二元使用 logit link，计数使用 log link；负二项固定 size $a = 5$，条件均值为 $\mu = e^{\eta}$、方差为 $\mu + \mu^2/a$。记 $\ell_{ik}(b; \beta_k) = \sum_j \log f(y_{ij}; \eta_{ijk})$、$\omega_{ik} = 1(U_i = k)$，则

$$\log L_c(\Omega) = \sum_{ik} \omega_{ik} \{\log \pi_k + \log \phi(b_i; 0, D_k) + \ell_{ik}(b_i; \beta_k)\}, \tag{1}$$

$$L(\Omega; Y) = \prod_i \sum_k \pi_k A_{ik}, \quad A_{ik} = \int e^{\ell_{ik}(b;\beta_k)} \phi(b; 0, D_k)\, db. \tag{2}$$

未观测时点不求和，未被选择的簇不需额外的随机效应。模型不含随机斜率或额外时间相关结构。

3 方法

3.1 MCEM 的 E 步与单目标 M 步

以 (U, b) 为缺失数据，将 McCulloch 的 MCEM 分解加入类别责任度。在旧参数 Ω^r 下，

$$\tau_{ik} = \frac{\pi_k A_{ik}}{\sum_h \pi_h A_{ih}}, \quad h_{ik}(b) = p(b_i \mid Y_i, U_i = k; \Omega^r) \propto e^{\ell_{ik}(b;\beta_k^r)} \phi(b; 0, D_k^r).$$

这与 Zeger–Karim 的条件随机效应计算直接相连；其全贝叶斯方案另抽样参数，本文不做参数 Gibbs。该文主要用拒绝抽样处理非标准条件分布，不能把所有步骤都写成 MH。沿用 Booth–Hobert 的独立 t 重要性抽样思想，以带回溯的 Newton 法求条件众数 $\widehat{b}_{ik}$ 和逆曲率 $V_{ik} = \{-\ell''_{ik}(\widehat{b}_{ik}) + 1/D_k^r\}^{-1}$。最多 80 轮，位移容差 10^{-9}，核对得分残差。每个 (i,k) 独立抽 M 个 $t_5(\widehat{b}_{ik}, s_{ik}^2)$，scale 平方为 $s_{ik}^2 = 3V_{ik}/5$，使方差为 V_{ik}。令

$$v_{ikm} = \frac{\pi_k^r e^{\ell_{ik}(b_{ikm};\beta_k^r)} \phi(b_{ikm}; 0, D_k^r)}{q_{ik}(b_{ikm})}, \quad a_{ikm} = \frac{v_{ikm}}{\sum_{h,l} v_{ihl}}.$$

于是 $\widehat{\tau}_{ik} = \sum_m a_{ikm}$，$w_{ikm} = a_{ikm}/\widehat{\tau}_{ik}$，层内有效样本量为 $\mathrm{ESS}_{ik} = 1/\sum_m w_{ikm}^2$，实际 MC 目标为

$$\widehat{Q} = \sum_{ikm} a_{ikm} \{\log \pi_k + \log \phi(b_{ikm}; 0, D_k) + \ell_{ik}(b_{ikm}; \beta_k)\}.$$

自归一化比率有有限样本偏差，不能称为无偏 log 似然。令 $N_k = \sum_i \widehat{\tau}_{ik}$，则

$$\pi_k^+ = N_k/n, \quad D_k^+ = \frac{\sum_{im} a_{ikm} b_{ikm}^2}{N_k}, \quad \beta_k^+ = \arg\max_\beta \sum_{im} a_{ikm} \ell_{ik}(b_{ikm}; \beta).$$

方差投影到允许区间，固定效应用解析梯度的 L-BFGS-B，最多 80 次；各簇目标除以 N_k，函数容差 10^{-12}、梯度目标 10^{-7}。检查同一个 $\widehat{Q}$ 不减并记录该尺度的投影梯度；内部仅完成目标改善时属于广义 M 步，不声称精确极大化。修订版不平均两次 M 步的参数。

3.2 独立验证、MC 标准误与停止

候选 Ω^+ 由训练样本得到，再在 Ω^r 下独立抽验证样本。设

$$d_{ikm} = \log L_{ci}(\Omega^+; k, b_{ikm}) - \log L_{ci}(\Omega^r; k, b_{ikm}), \quad \widehat{\Delta}_i = \sum_{km} a_{ikm} d_{ikm}, \quad z_{ikm} = a_{ikm}(d_{ikm} - \widehat{\Delta}_i).$$

将各层独立样本均值的方差经比率的一阶导数传播，得到分层自归一化 IS 的 delta 方法估计

$$\widehat{\mathrm{Var}}_{MC}(\widehat{\Delta}) = \sum_{ik} \frac{M}{M-1} \sum_m (z_{ikm} - \bar{z}_{ik})^2, \quad \widehat{\Delta} = \sum_i \widehat{\Delta}_i. \tag{3}$$

用个体联合均值 $\widehat{\Delta}_i$ 居中，故包含责任度归一化误差；只按每簇条件均值居中会遗漏它。独立验证使候选在误差计算中可视为固定。令 s_Δ 为标准误，$L = \widehat{\Delta} - 1.96 s_\Delta$、$H = \widehat{\Delta} + 1.96 s_\Delta$。$L > 0$ 则接受，否则保持旧参数。不能确定上升且未满足精度时增样；ESS 比例第 10 百分位小于 0.4 也增样。每层 M 从 128 加倍至最多 8192。连续三轮满足 $H/n < 5 \times 10^{-5}$、$s_\Delta/n < 2 \times 10^{-5}$、缩放位移 $\max_j |\theta_j^+ - \theta_j^r|/(1 + |\theta_j^r|) < 0.01$、M 步投影梯度 $< 10^{-4}$ 则停止。θ 为固定效应、log 方差、混合比例 logits。最多 250 轮；样本上限仍不能决策则标记预算不足，不算收敛。正态区间是独立 IS 的渐近点态近似，不消除有限样本比率偏差，多轮查看也不是整个算法的 95% 上升保证。不直接继承原文完整收敛定理；用经验重复核对 MCSE，以积分估计核对最终差距。

3.3 高斯变分近似：现代扩展

取 $q(U_i=k,b_i)=r_{ik}\mathcal{N}(b_i;m_{ik},s_{ik}^2)$，个体间分解，保留标签与随机效应的条件依赖。证据下界为

$$\mathcal{L}(q,\Omega)=\sum_{ik} r_{ik}\{\log\pi_k-\log r_{ik}+F_{ik}\}, \tag{4}$$

$$F_{ik}=\mathbb{E}_q\ell_{ik}(b)-\frac{1}{2}\left\{\frac{m_{ik}^2+s_{ik}^2}{D_k}-1+\log\frac{D_k}{s_{ik}^2}\right\}. \tag{5}$$

固定参数时 $\log L-\mathcal{L}=\mathrm{KL}(q\|p(U,b\mid Y;\Omega))\geq 0$。每个局部 (m,s) 最大化 F，然后 $r_{ik}\propto\pi_k e^{F_{ik}}$。以 $b=m+sZ$、$Z\sim\mathcal{N}(0,1)$，

$$F_m=\mathbb{E}\ell'(m+sZ)-m/D,\quad F_s=\mathbb{E}[Z\ell'(m+sZ)]+1/s-s/D.$$

若 $H=-\ell''\geq 0$，负 Hessian 为

$$\mathbb{E}\left[H\begin{pmatrix}1 & Z\\ Z & Z^2\end{pmatrix}\right]+\mathrm{diag}(1/D,1/D+1/s^2),$$

故本题三类正确似然的局部目标在 $s>0$ 严格凹。用独立二维 Newton 加回溯，保持 s 正且目标不减；最多 100 轮，局部梯度目标 10^{-7}，最终残差另行记录。Poisson 使用解析式

$$\mathbb{E}_q\ell_{ik}=\sum_j\{y_{ij}(x_{ij}^\top\beta_k+m_{ik})-e^{x_{ij}^\top\beta_k+m_{ik}+s_{ik}^2/2}-\log(y_{ij}!)\}.$$

其余响应使用 31 点正权 GH，$\mathbb{E}H(Z)\approx\pi^{-1/2}\sum_l a_l H(\sqrt{2}x_l)$。有限积分只是近似目标，不能无条件称其仍为精确似然的严格下界。外层最大化局部变分参数优化后的剖面 ELBO。包络梯度为

$$\partial_{\beta_k}\mathcal{L}=\sum_i r_{ik}\mathbb{E}_q\partial_{\beta_k}\ell_{ik}, \tag{6}$$

$$\partial_{\log D_k}\mathcal{L}=\tfrac{1}{2}\sum_i r_{ik}\{(m_{ik}^2+s_{ik}^2)/D_k-1\}, \tag{7}$$

$$\partial_{\alpha_k}\mathcal{L}=\sum_i r_{ik}-n\pi_k,\quad \alpha_k=\log(\pi_k/\pi_K),\ k<K. \tag{8}$$

以每个体平均负目标作 L-BFGS-B，函数容差 10^{-12}、梯度目标 2×10^{-6}、最多 300 轮；最终投影梯度 $<10^{-4}$ 且局部残差 $<10^{-5}$ 才标记数值收敛。

3.4 积分参照、初始化与实现

随机截距一维，使用 61 点自适应 GH 计算 A_{ik}：以条件众数和逆曲率构造正态密度 q_N，求 $\mathbb{E}_{q_N}[e^{\ell_{ik}}\phi/q_N]$。最大化观测 log 似然，Fisher 恒等式给出其梯度，即把上面的变分期望换成条件积分期望。优化设置同 GVA，最后用 101 点复核。称为数值积分 ML（QML）参照，不称为全局真值。单观测对 η 的得分为 $y-p$、$y-e^\eta$、$y-(y+5)p_a$，负二阶导数为 $p(1-p)$、e^η、$(y+5)p_a(1-p_a)$；$p=\mathrm{logit}^{-1}(\eta)$、$p_a=e^\eta/(5+e^\eta)$。对 β 乘 $(1,t)^\top$ 后求和。Poisson 还利用随机截距充分统计量降低重复计算，不截断 e^η 改变模型，机器溢出的零权重尾部按数值零处理。

每拟合 3 起点：个体响应均值和时间斜率构成特征，$\widehat{d}_i=\sum_j(t_{ij}-\bar{t}_i)y_{ij}/\max\{\sum_j(t_{ij}-\bar{t}_i)^2,10^{-6}\}$。二元平滑均值为 $p_i=(\sum_j y_{ij}+0.5)/(T_i+1)$，特征为 $\{\mathrm{logit}(p_i),\widehat{d}_i/[p_i(1-p_i)]\}$；计

数为 $\{\log(\bar{y}_i+0.1), \widehat{d}_i/(\bar{y}_i+0.1)\}$。斜率特征截在 $[-4,4]$，各特征加标准差 0.08 的正态扰动，用 k-means++ 加 30 轮聚类初始化：中心作 β，组内人数比例作 π，各方差初值 0.5，不用真实标签。$\beta \in [-8,8]$、$D_k \in [0.005,5]$；QML/GVA logits 限 $[-16,16]$，MCEM 遇到 $\pi_k < 10^{-12}$ 报告数值空分量。MCEM/QML 按最终积分似然选起点，GVA 按 ELBO 选；最大责任度给聚类。匹配真实标签仅用于评价，不证明识别性或全局最优。

3.5 同目标条件 MCMC

固定同一 QML 参数，目标为 $p(U,b \mid Y;\widehat{\Omega})$，不抽样参数。最初分开更新标签和随机效应的 Gibbs/MH 检查中，Poisson 接受率约 0.877，但最大 split 诊断约 36，链未混合；该输出保留，不作精度真值。标签与随机截距的强依赖需要联合跨模式更新。正式比较使用标准联合独立 MH：由 $g_i(h,b^*) = \pi_h q_{ih}(b^*)$ 提议新标签和随机效应。若当前标签为 k，目标与提议中的混合比例抵消后，接受率为

$$\min\left\{1, \frac{e^{\ell_{ih}(b^*)}\phi(b^*;0,D_h)q_{ik}(b_i)}{e^{\ell_{ik}(b_i)}\phi(b_i;0,D_k)q_{ih}(b^*)}\right\}.$$

q_{ih} 沿用上述基于条件众数和曲率的 t_5 提议，在固定参数下不再调整。三个响应场景第一次重复各取前 30 个体，4 链各 2000 次预热、8000 次保留。起始标签为 0、1、2、0，b 为相应条件众数。保存全部样本；报告经典 split $\widehat{R}$（非秩标准化）和长度 100 的批均值 MCSE；均值、方差、责任度与 101 点积分比较。有限链不是无误差的后验真值，也不能用来声称参数后验区间的准确性。

4 模拟研究

4.1 设计与评价

基准为 $n=300, T=20$，等距时间 $[-1,1]$，真值和拟合 $K=3$，$\pi=(0.5,0.3,0.2)$、$D_k=0.5$，二元响应；β_k 为 $(-1.5,-1.8),(0.5,1.8),(1.5,-1.8)$。另保留作业建议 $(-1.5,0.2),(0.5,-0.2),(1,0.3)$ 作为困难场景。14 场景为：基准；β_k 向三簇均值收缩一半；作业建议参数；$n=100,1000$；$T=10,50$；拟合 $K=2,4$；$D_k=0.1,1.5$；Poisson；负二项；不规则时间。最后一项先生成每人 20 个排序的均匀时间，再独立取 $T_i \in \{10,\dots,20\}$ 并保留前 T_i 个，因此部分人的观测偏向早期，不声称均匀覆盖区间。GVA/QML 各场景 5 次重复；MCEM 在基准二元、Poisson、负二项各 5 次，每次 3 起点，共 70 份不同数据、155 次拟合。不声称每个方法在每个场景均运行。数据种子 $20261110+10000s+r$，场景 $s=0,\dots,13$ 按上段顺序，重复 $r=0,\dots,4$；拟合种子加 200000，起点再加 $1009h$，MC 流另加 73。MCMC 种子为 $20261110+900000+f$，$f=0,1,2$ 为二元、Poisson、负二项。服务器可用 16 个逻辑 CPU、内存限额约 80 GiB，使用 8 个并行拟合进程，每进程数值库单线程；Python 3.11.4、NumPy 2.4.2、SciPy 1.16.3、Matplotlib 3.10.8。源码、配置、逐起点记录、全部保留 MCMC 样本及 SHA256 清单在本地保存。

ARI 对标签置换不变并校正随机一致性；错分率用最优一对一匹配。正确 K 时按固定效应距离匹配，分别计算固定效应、方差、比例的 RMSE；误设 K 不强行一一比较参数。表中为重复均值，ARI 另列样本标准差；5 次重复仍只支持初步观察。全部预算不足或未收敛结果保留。

4.2 结果

表 1: 全部 14 场景的 5 次重复。ARI 为均值 ± 标准差；RMSE 为 GVA 跨重复均值，误设 K 不比较参数。收敛数按 QML/GVA，分母各为 5。

场景	ARI(QML)	ARI(GVA)	β RMSE	D RMSE	π RMSE	收敛
基准	0.885±0.038	0.885±0.038	0.133	0.181	0.033	5/5
分离减半	0.412±0.082	0.411±0.083	0.439	0.282	0.130	5/5
作业建议参数	0.411±0.121	0.363±0.118	0.891	0.552	0.249	5/5
$n = 100$	0.806±0.101	0.806±0.101	0.301	0.251	0.050	5/5
$n = 1000$	0.882±0.021	0.882±0.020	0.075	0.120	0.025	5/5
$T = 10$	0.734±0.125	0.754±0.090	0.303	0.430	0.053	5/5
$T = 50$	0.939±0.032	0.939±0.032	0.088	0.121	0.026	5/5
$K = 2$	0.593±0.038	0.593±0.038	–	–	–	5/5
$K = 4$	0.820±0.038	0.822±0.037	–	–	–	5/5
$D = 0.1$	0.970±0.013	0.970±0.013	0.094	0.051	0.022	5/5
$D = 1.5$	0.654±0.110	0.662±0.114	0.419	0.584	0.107	5/5
Poisson	0.959±0.016	0.955±0.014	0.064	0.120	0.030	5/5
负二项	0.973±0.014	0.975±0.011	0.073	0.071	0.029	5/5
不规则时间	0.609±0.047	0.616±0.042	0.249	0.455	0.041	5/5

表 2: 三类响应的同数据比较。各格为 5 次均值；耗时为三起点总墙钟秒数。$\Delta\ell/n = (\ell_{\mathrm{QML}} - \ell_{\mathrm{fit}})/n$，fit 表示对应方法，可因不同局部解出现负值，不是 KL 散度。

响应	方法	ARI	错分率	β RMSE	秒	收敛/5	$\Delta\ell/n$
基准	QML	0.885±0.038	0.042	0.133	24.3	5	0.00000
基准	GVA	0.885±0.038	0.042	0.133	40.2	5	0.00000
基准	MCEM	0.899±0.020	0.037	0.126	728.6	5	0.00027
Poisson	QML	0.959±0.016	0.014	0.063	7.6	5	0.00000
Poisson	GVA	0.955±0.014	0.015	0.064	8.2	5	0.00001
Poisson	MCEM	0.956±0.022	0.015	0.090	373.3	5	0.00407
负二项	QML	0.973±0.014	0.009	0.073	35.8	5	0.00000
负二项	GVA	0.975±0.011	0.009	0.073	71.7	5	0.00001
负二项	MCEM	0.969±0.008	0.011	0.094	2779.9	5	0.00092

基准 GVA 的平均 ARI 为 0.885、错分率 0.042；分离减半和作业建议参数时 ARI 为 0.411、0.363。全部 155 次拟合中，155 次满足各自停止标准；未收敛和边界记录完整保留。各因素的实测结果见表，不从 5 次重复推断普遍优势。不同目标的差异、同一目标的积分误差和参数恢复误差分别评价。Poisson 场景 GVA 三起点平均耗时 8.2 秒、收敛 5/5；其解析期望与剖面优化的实现不再采用旧版高维局部数值优化，但新旧硬件/容差不同，不能直接用旧耗时计算加速比。MCEM 所选解的每个体观测目标投影得分最大范数范围为 0.001222 至 0.05756；小 Q 增量并不直接保证观测得分为零，表中的剩余似然差也须同时查看。MCEM 在二元、Poisson、负二项下的方差参数 RMSE 依次为 0.145、0.112、0.078，混合比例 RMSE 依次为 0.029、0.026、0.034。另有 4 次所选

起点记录过内部求解器非成功状态，与外层停止标记分开保存。有 28 次所选解触及预设方差或固定效应边界，参数解释受约束影响。样本量 100 至 1000 时，GVA 固定效应 RMSE 由 0.301 变为 0.075；序列 10 至 50 次时 ARI 由 0.754 变为 0.939。方差 0.1 与 1.5 的 ARI 为 0.970/0.662；拟合 2 簇与 4 簇为 0.593/0.822，不规则时间为 0.616。基准 5 份数据中，每个体终目标的三起点极差最大值，QML、GVA、MCEM 依次为 1.19e-10、4.993e-11、0.0003116；各方法按自己的目标衡量，MCEM 差异还含 MC 波动，不能据此证明全局最优。

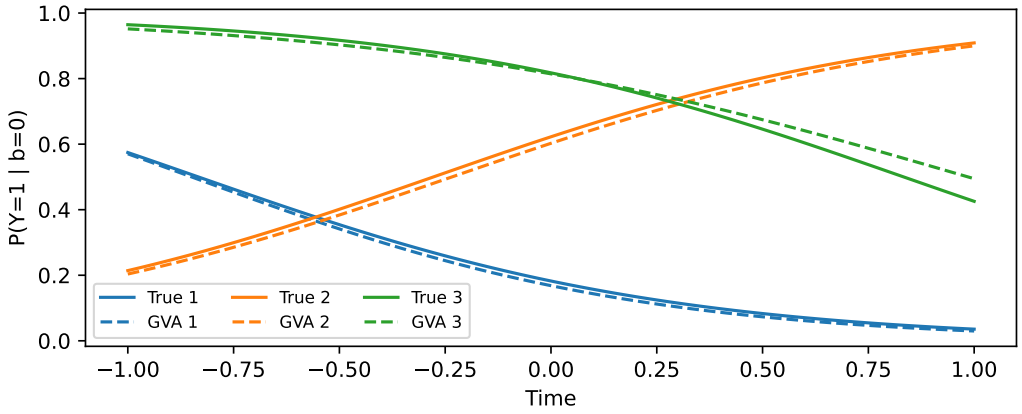


图 1: 基准第一次重复的真实与 GVA 拟合条件轨迹，随机截距取 0，不是总体平均轨迹。

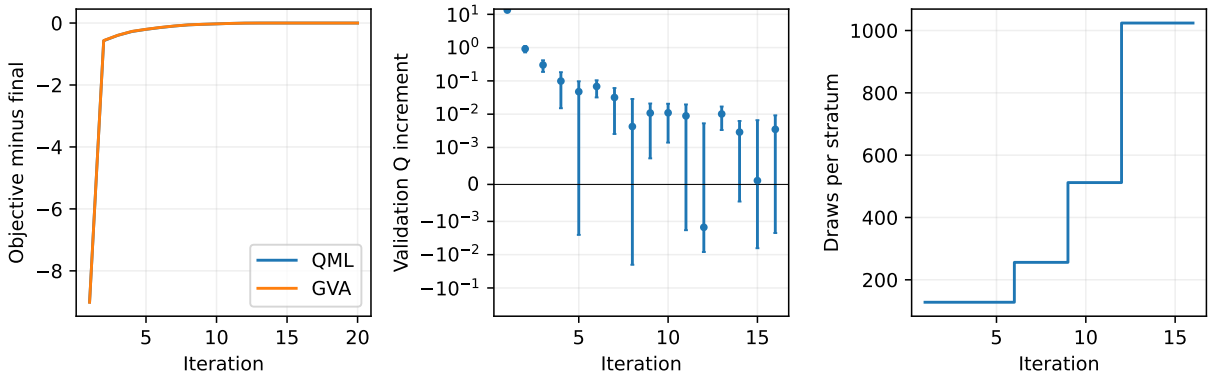


图 2: 基准第一次重复所选起点：各自目标相对终值、MCEM 验证增量区间、每层抽样量。目标曲线不用于跨目标直接比较。

4.3 数值与条件分布核验

剖面梯度与中心差分核对；Poisson 解析期望与高阶积分核对，并检查 $\eta > 50$ 的梯度一致性。MCSE 与 80 次独立抽样的经验标准差对照，细节见 `qa/validation.json`。

表 3: 同一固定 QML 参数下，30 个体条件分布的核验。误差对 101 点积分计算；成对数值为 MCMC/GVA。方差比为各个体边缘 b_i 方差之和相对于积分的比。

响应	MH 接受率	最大 split $\widehat{R}$	均值 RMSE	责任度 RMSE	方差比
基准	0.365	1.0021	0.0083/0.0002	0.0026/0.0001	0.995/0.997
Poisson	0.357	1.0038	0.0045/0.0002	0.0011/0.0000	1.002/0.986
负二项	0.354	1.0016	0.0047/0.0002	0.0007/0.0000	0.996/0.990

在小规模 80 次独立 IS 检验中，经验标准差与 delta 方法预测标准差之比分别为 1.025、1.040、1.013。这是误差公式的有限验证，不是所有场景的覆盖率证明。全部所选参数的 61 与 101 点积分 log 似然最大差为 1.55e-11。全部 MCEM 起点实际生成 7,439,846,400 个提议值；若对相同的已发生迭代都固定使用每层 8192，则为 45,608,140,800 个，前者占 0.163。这仅比较相同迭代数的抽样量，不是固定样本算法达到同等精度的时间比。14 场景第一次重复的 GVA，以 61 点替换 31 点后重新求局部最优，剖面 ELBO 最大绝对差为 1.82e-12。条件 MCMC 的个体均值批均值 MCSE（对 30 人再平均）依次为 0.0069、0.0032、0.0048。本例 GVA 与积分的差异很小，有限 MCMC 仍有抽样误差；这不表示变分推断普遍比充分计算的 MCMC 更准确。这些结果针对固定参数的潜变量目标，未构造全贝叶斯参数区间。

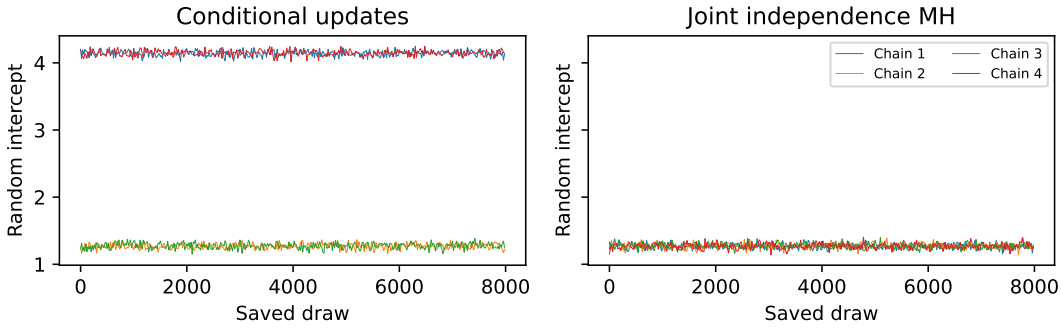


图 3: Poisson 同一参数下的链。选择原分开更新中 split 诊断最大的个体作示例；右图用标准联合独立 MH 跨越标签–随机截距的联合模式。轨迹每 20 次显示一点，诊断使用全部保留样本。

5 讨论

MCEM 继承缺失数据分解和独立重要性抽样；增量误差包括责任度归一化。GVA 为现代扩展，利用高斯族及 Poisson 解析结构。其误差包含变分族限制、积分与优化误差；同一参数的 MCMC/积分比较只检验潜变量近似，不能验证参数后验区间。单个 GLMM 中已有的 GVA 一致性结果也不能直接当作本混合模型的一致性证明，本文仅作数值验证。

局部变分目标严格凹不代表整体混合目标凹，3 起点不能排除局部最优。轨迹重叠和较大随机效应方差使成员难区分，真实标签匹配只校正编号。K 过小合并簇、过大可能拆分簇；本文不做数据驱动选 K。点估计没有参数先验敏感性实验；随机效应分布是模型假设，不是参数先验。若做全贝叶斯推断，应使用适当可积先验，并让 VB 与 MCMC 针对同一后验比较。

一维 GH 提供便宜参照；更多随机效应会带来积分维数增长，IS 也可能退化。样本存储约 $O(nKM)$，似然约 $O(nKTM)$，Poisson 可用充分统计量降低重复计算。只比较到 $n = 1000$，不声称解决大规模计算。耗时含全部起点与诊断，云端进程竞争及不同停止标准影响墙钟时间，不能将速度比解释为同等精度下的普遍结论。本次三个响应场景中，GVA 的实测耗时均小于 MCEM，而一维 QML 又均快于 GVA；因此本题的低维积分结构本身有计算优势，不能仅因采用现代扩展就预设其最快。

正态随机效应和给定 (U, b) 后时间独立是假设，未对其误设额外模拟。MCEM 区间是渐近点态近似，预算可能不足；积分法和 GVA 也保留非成功状态。数值稳定不是全局最优或统计识别性的证明。

模拟设计中，原建议二元参数较难区分，故同时保留困难场景和更分离的基准。随机截距本身可使边缘计数过度离散，负二项另增条件过度离散；固定 size=5 不代表解决未知离散度估计。不同族相同线性预测器不意味着相同信息量。后续宜先增加重复并研究困难场景，避免任意堆叠模型。

参考文献

[1] Zeger, S. L. and Karim, M. R. (1991). Generalized linear models with random effects: a Gibbs sampling approach. *JASA*, 86, 79–86.

[2] McCulloch, C. E. (1997). Maximum likelihood algorithms for generalized linear mixed models. *JASA*, 92, 162–170.

[3] Booth, J. G. and Hobert, J. P. (1999). Maximizing generalized linear mixed model likelihoods with an automated Monte Carlo EM algorithm. *JRSS-B*, 61, 265–285.

[4] Ormerod, J. T. and Wand, M. P. (2012). Gaussian variational approximate inference for generalized linear mixed models. *JCGS*, 21, 2–17. doi:10.1198/jcgs.2011.09118.

[5] Caffo, B. S., Jank, W. and Jones, G. L. (2005). Ascent-based Monte Carlo expectation–maximization. *JRSS-B*, 67, 235–251. doi:10.1111/j.1467-9868.2005.00499.x.